26-1 머신러닝 팀과제

이상신호 감지 기반 비정상 작동 진단

4-모델 앙상블 베이스라인 분석 및 성능 개선 프로젝트

발표자 · 이재하

0.8598

Baseline Private · Macro-F1

0.8744

Final Private · Macro-F1 (+0.0146)

[2팀]

권지원 · 이나경 · 이성진 · 이재하

CONTENTS

목차

01 과제 개요 및 베이스라인 구조

02 베이스라인 한계 진단

03 최종 코드 핵심 — LDA Feature Augmentation · TabNet 5-Fold CV

04 Auto-Weight 앙상블의 원리 · ReLU 가중치 문제

05 SNN 모델 도입 — ReLU 대체

06 SNN 모델 도입 — ReLU 대체

07 최종 코드 구조

08 Before / After 비교

09 각자 실험 결과 ① — 나경 · 지원

10 각자 실험 결과 ② — 성진

11 각자 실험 결과 ③ — 재하

12 두 코드 비교 → 공통 방법론 추출

13 공통 기반 위 통합 시도

14 공통 기반 위 통합 시도

01

과제 개요 및 베이스라인 구조

21개 클래스 다중분류 · DACON 공개 6등 코드 (4-Model Ensemble + Hungarian)

21
비정상 클래스
0 ~ 20번

52
센서 변수
X_01 ~ X_52

21,693
학습 데이터 행
Train (균등)

Macro-F1
평가 지표
클래스 평균 F1

베이스라인 파이프라인

1단계
Input
52개 센서

→

2단계
4-Model 학습
TabNet · MLP×2
AutoGluon

→

3단계
Soft Voting
균등 가중치
0.25씩

→

최종
Hungarian
균등 분배
강제 후처리

→ 4-모델 균등 가중 평균 + Hungarian 균등 분배 강제

02

베이스라인 한계 진단

이후 모든 실험의 출발점 · 구조적 한계 4가지

01

Feature Engineering 부재

StandardScaler만 적용한 채 원본 52개 센서를 그대로 사용. 정보 추출 전혀 없음 → 모델이 학습할 신호가 제한됨.

→ **LDA 20차원 추가 (Fold-safe)**

02

데이터 누수 (Scaler fit)

전체 데이터로 scaler fit 후 train/val 분리 → val 분포 정보가 scaler에 새어 들어감. CV 점수 과대평가.

→ **Fold-safe Scaling (train fold로만 fit)**

03

검증 / 평가지표 불일치

TabNet 1-split·accuracy, MLP 5-fold·F1, AG 자동·log_loss. 모델별 데이터 사용량과 학습 목표가 달라 비교 불가.

→ **5-fold StratifiedKFold + Macro-F1 통일**

04

모델 별 기여도 미검증

MLP-ReLU와 MLP-GELU 모두 동일 구조 (BatchNorm + Residual). 활성화 함수만 다른 거의 같은 모델 → 앙상블 가중치 손실.

→ **Auto-Weight 탐색 + SNN 대체**

→ 4가지 한계가 이후 LDA · Fold-safe · 통일 검증 · SNN 도입의 출발점

LDA Feature Augmentation · TabNet 5-Fold CV

거리 기반 피처가 도메인 정보 없는 블랙박스 문제 해결

LDA Feature Augmentation

X_01 ~ X_52는 비식별 센서

어떤 변수가 어떤 의미인지 모름

거리 기반 피처가 효과적

클래스 중심까지의 거리 정보 추출

LDA = 클래스 분리 최대화

Fisher Discriminant 기준

TabNet 5-Fold CV

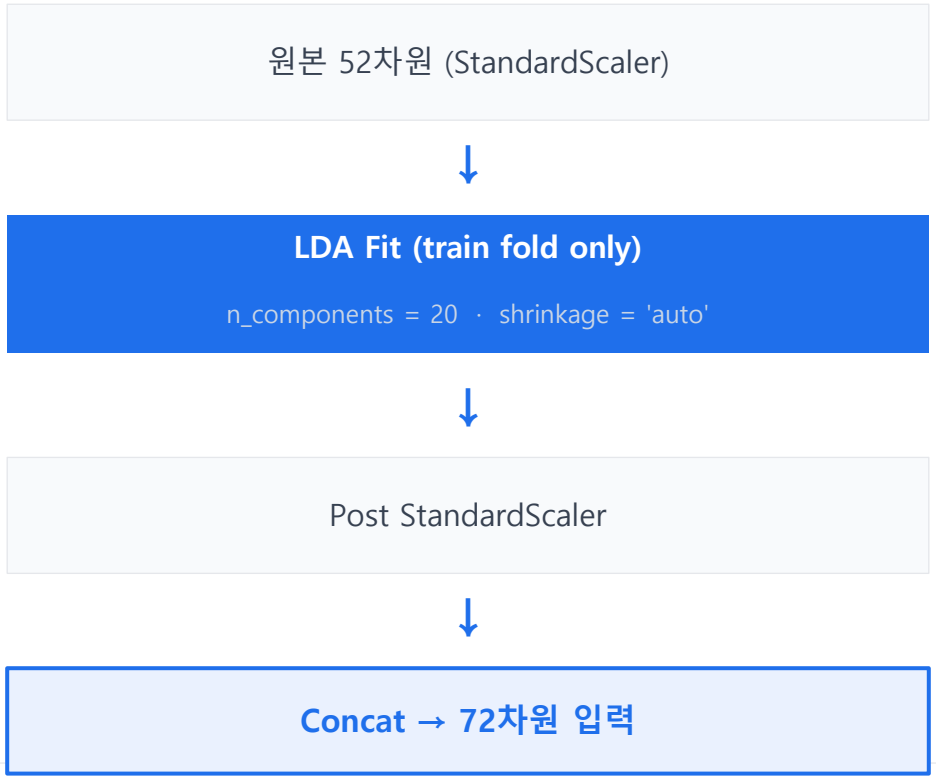
StratifiedKFold (k=5)

기존 1-split → variance ↓, OOF 생성

Self-Supervised Pretraining

train+test 비지도 사전학습 → Covariate Shift 대응

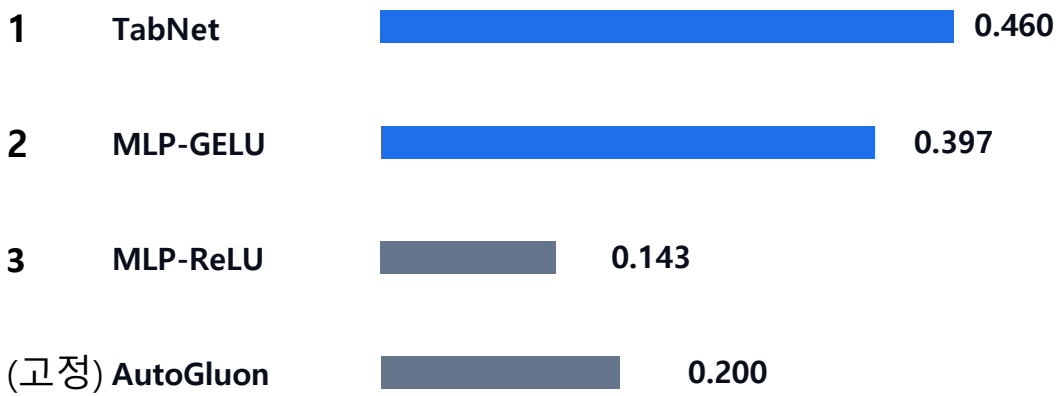
LDA 동작 방식



Auto-Weight 앙상블 · ReLU 가중치 문제

OOF 기반 자동 탐색 · ReLU와 GELU의 구조적 중복 발견

Auto-Weight 탐색 결과 (OOF F1 = 0.8780)



ReLU 모델의 가중치가 압도적으로 낮음

ReLU가 낮은 이유 · 분석

"단일 성능이 아니라 다양성(Diversity)을 보상"

- ReLU와 GELU 모두 동일 BatchNorm + Residual 구조
- 활성화 함수만 다른 거의 같은 모델
- 예측이 거의 중복 → 가중치 손실
- → 진짜 다양한 모델로 교체 필요

→ ReLU 모델 자체가 다양성 확보에 실패

05 · 최종 코드 핵심

SNN 모델 도입 · ReLU 대체

ReLU → SNN 교체 하나로 앙상블 다양성 확보

SNN 이란?

Self-Normalizing Network

(Klambauer et al. 2017)

SELU 활성화

Scaled Exponential Linear Unit · 자체 정규화

AlphaDropout

SELU 분포를 보존하는 dropout (vs 일반 dropout)

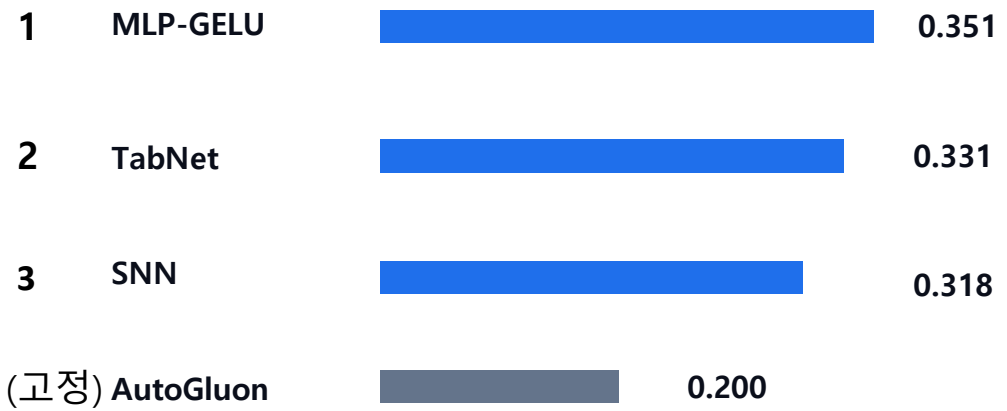
BatchNorm 불필요

활성화 함수 자체가 정규화 역할

LeCun Normal 초기화

SELU 전용 초기화로 안정성 ↑

Auto-Weight 탐색 결과 (OOF F1 = 0.8780)



가중치 불균형 완화

→ 앙상블 가중치 정상화

SNN 모델 도입 · ReLU 대체

모델 수를 늘리는 것이 아니라, 하나의 슬롯을 학습 동역학이 다른 모델로 교체 — '추가'가 아닌 '치환'이 통한 케이스

왜 SNN으로 교체했나?

▸ ReLU ≈ GELU — 중복 신호

두 모델 모두 BatchNorm + Residual 구조 → OOF 예측이 강하게 상관 → 앙상블에서 중복 신호

▸ SNN: 학습 동역학 자체가 다름

SELU 자기 정규화 (batch 통계 없음) + AlphaDropout으로 분포 보존 → 에러 패턴이 달라 보완 효과

▸ Auto-weight가 자동으로 포착

Nelder-Mead OOF 최적화가 SNN의 보완성을 감지 → 자연스럽게 가중치 부여

ReLU vs SNN 비교

항목	MLP-ReLU	SNN
정규화	BatchNorm	SELU 자체
Dropout	Dropout(0.2)	AlphaDropout(0.1)
가중치 초기화	Kaiming	LeCun Normal
학습률	1e-3	5e-4 (안정성)
앙상블 기여	중복 신호	보완 효과

v1_original (ReLU) → SNN 버전

0.8733 → 0.8744

최종 코드 구조

LDA + 4-Model Ensemble + Auto-Weight + Hungarian · Private 0.8744



모델	Validation 방식	Loss / 평가	변경 내용
TabNet	5-fold StratifiedKF	Macro-F1	Self-supervised Pretrain + LDA 20차원
MLP-GELU	5-fold StratifiedKF	Macro-F1	best_state deepcopy + ClassWeight
SNN	5-fold + Seed 3개	Macro-F1	ReLU 대체 (SELU + AlphaDropout)
AutoGluon	내부 stacking	Macro-F1	eval_metric 변경 + LDA augmented

베이스라인 vs 최종 코드 비교

변경된 모든 요소 · 한눈에 보기

항목	베이스라인	최종 코드
Feature Engineering	없음 (52차원 원본)	LDA 20차원 추가 → 72차원
Scaling	전체 데이터 fit (누수)	Fold-safe (train fold만 fit)
TabNet 검증	1-split + Accuracy	5-fold + Macro-F1
TabNet 사전학습	Supervised only	Self-supervised Pretrain + Fine-tune
ReLU 모델	MLP-ReLU (GELU와 중복)	SNN (SELU + AlphaDropout)
앙상블 가중치	균등 0.25씩 고정	Auto-Weight (Nelder-Mead) + AG 0.2 고정
AutoGluon	log_loss	f1_macro
EarlyStopping	없음	Patience = 20
클래스 가중치	없음	compute_class_weight('balanced') 적용
best_state 저장	참조 복사 (버그)	deepcopy(model.state_dict()) (수정)
평가 결과	**Private 0.8598**	**Private 0.8744**

09

각자 실험 결과 ① · 나경 + 지원

베이스라인 대비 — 시도 내용 · 점수 · 원인 분석

나경 · 실험 A ~ D (Private 점수 기준)

실험	핵심 변경	Private	vs 베이스	원인 분석
A	AutoGluon → Tree 3종 + FE + TabNet 5-fold + Dirichlet	0.8630	+0.002	Tree가 NN과 inductive bias 달라 보완. AG 제거로 다양성 손실
B	모델 유지 + Per-Fold Scaling + 클래스별 가중치 튜닝	0.8638	+0.003	Per-Fold로 누수 차단 + 소수 클래스 recall 개선
C	실험 B 기반 + LightGBM 추가 + Dirichlet 가중치 최적화	0.8626	+0.002	Dirichlet 가중치가 OOF에 과적합됐을 가능성
D	AutoGluon → LGB+XGB + PCA 10개 + 코사인 LR + seed 3개	0.8589	-0.002	PCA 정보 손실 + 변경사항 너무 많아 원인 특정 불가

지원 · 실험 A ~ E (Private 점수 기준)

실험	핵심 변경	Private	vs 베이스	원인 분석
A	버그 발생 — LightGBM 학습/검증 데이터 혼용	—	측정불가	X 전체로 학습 후 X_val로 평가 → 성능 0.97로 부풀려짐
B	A 버그 수정 + RobustScaler + 중복변수 제거 + LGB 추가	0.8599	+0.001	MLP 향상. TabNet(-0.02), LGB(0.79)가 앙상블 발목 잡음
C	앙상블 조합 최적화 — GELU 단독 사용	0.8601	+0.003	다양성 없는 앙상블=독
D	Tree 3종(LGB+XGB+CatBoost) 추가	0.8590	-0.002	트리 성능 낮아 희석. CatBoost 과적합(Train-Val 갭 0.14)
E	LDA+RobustScaler+Fold-safe+AutoWeight+EarlyStop 통합	0.8369	-0.024	한꺼번에 너무 많이 변경 → 원인 특정 불가

각자 실험 결과 ② · 성진

피처 엔지니어링 탐색 (LightGBM OOF F1) + 모델·후처리 실험 (베이스라인 0.8598)

실험 A-1 ~ A-4 · Feature Engineering 탐색 (LightGBM OOF F1 기준)

실험	핵심 변경	OOF F1	vs 원본	원인 분석
A-1	FE 1차 — 행통계 7개 + 핵심 4센서 조합 17개 추가	0.8045	**+0.002**	클래스별 센서 패턴 행 단위 요약 → 유의미한 신호
A-2	FE 2차 — Top5 센서 ratio/diff/mul 45개 추가	0.8043	**-0.0002**	Feature Importance = 트리 분할 빈도일 뿐. 중복 피처
A-3	FE 1.5차 — 1차+2차 Top4 선별 21개	0.8020	**-0.0003**	선별해도 노이즈. 중요해 보인 피처도 결국 중복 정보
A-4	FE 1차 + X_01 제거 (68개 피처) → 채택	0.8050	**+0.003**	빼는 것도 개선. X_01 제거로 노이즈 감소 + 신호 강화

→ **핵심 교훈: Feature Importance ≠ 성능 기여도 · FE는 더하기 게임이 아닌 조합 최적화**

실험 B ~ E · 모델 · 후처리 실험 (Private 점수 기준)

실험	핵심 변경	Private	vs 베이스	원인 분석
B	FE + 5-fold + Argmax 후처리	0.8146	**-0.045**	Argmax가 앙상블에서 치명적
C	B + Hungarian 복원	0.8621	**+0.002**	앙상블엔 Hungarian 필수 확인
D	AutoGluon 제외 (3모델)	0.8582	**-0.002**	다양성 손실. AG 기여 확인
E	Train+Test 통합 정규화	0.8635	**+0.004**	Covariate Shift 대응 효과

11

각자 실험 결과 ③ · 재하

최종 코드의 기반 — 파이프라인 정리 + LDA Feature Augmentation

재하 · 실험 A ~ v9 (Private 점수 기준)

실험	핵심 변경	Private	vs 베이스	원인 분석
A	best_state 버그 픽스 + EarlyStopping + Fold-safe + f1_macro	—	**기준**	기반 정비 단계 · Private 측정 없음
B	LDA Feature Augmentation (52→72차원)	**0.8717**	**베이스**	LDA + Hungarian quota가 점수 대부분 견인
C	Cosine LR scheduler 도입	**0.8037**	—	LR restart가 EarlyStop과 충돌해 수렴 전 종료
D	+ Row 통계 9개 + FFT 6개 + Mixup	**0.8669**	**-0.005**	FFT 시계열 가정 불확실 · Mixup이 SupCon과 충돌
v7	LDA + Maha 21dim + 트리 5종 (NN 제거) + LR 스태킹	0.8525	-	Maha만 직교 신호 · NN 제거로 카테고리 다양성 손실
v9	QDA proba 21dim + Soft KMeans 38dim (72→131dim)	**0.8451**	**N/A**	LDA가 잡은 군집 정보의 변형 · 차원만 1.8배로 비대

→ 핵심 교훈: 피처 추가는 더하기 게임이 아닌 조합 최적화 · LDA가 이미 잡은 신호와 겹치는 피처는 손해

12

두 코드 비교 → 1차 코드 추출

성진 (0.8635) · 재하 (0.8717) — 공통적으로 사용된 방법론으로 최종 코드의 기반을 세우다

두 코드 공통 방법론 — 최종 코드의 기반

공통 방법론	성진 적용 방식	재하 적용 방식
MLP (ReLU/GELU) + Residual Block	동일 구조	동일 구조
SupCon Loss + Center Loss	0.5 / 0.1 가중치	동일
Label Smoothing	CE 0.05 적용	동일
TabNet 5-fold	5-fold, sparsemax	5-fold (세부 상이)
5-Fold StratifiedKFold	전 모델 공통	전 모델 공통
Hungarian 후처리 + Macro-F1	quota 기반 할당	동일

성진 방법론

- 통합 정규화 — Train+Test StandardScaler (Covariate Shift 대응)
- FE: 행통계 7개 + 핵심센서 조합 + X_01 제거 (52→68차원)
- Argmax vs Hungarian 실험 검증 → Hungarian 채택 근거

재하 방법론

- LDA Feature Augmentation — 20차원 판별 축 (52→72차원), fold-safe
- best_state 복사 + Fold-safe Scaling — 데이터 누수 차단
- Auto-weight Ensemble (Nelder-Mead) + TabNet Self-Supervised Pretrain

13

1차 기반 위 통합 시도

재하 코드(0.8733) 기준 · 피처 추가 검증 · 팀 전체 역할 분담 실험

1차 시도 — 공통 기반 + 피처 추가 검증 (기준: 재하 코드 Private 0.8733)

시도 내용	Private	vs 기준 (0.8733)	실패 원인
재하 코드 (기준)	0.8733	—	기준
+ 행통계 7개 추가	0.8663	**-0.007**	피처 추가가 오히려 노이즈로 작용
+ 성진님 FE 3종 통합 (행통계 + 핵심센서 + X_01 제거)	0.8716	**-0.002**	일부 회복했지만 기준 미달
+ 행통계 7개 + Mahalanobis 거리 피처 21개	0.8724	**-0.001**	Maha 소폭 개선이나 기준 넘지 못함

→ **핵심 발견: 피처를 추가할수록 기준(0.8733)보다 낮아짐 — 재하 코드가 이미 최적화된 상태**

2·3차 시도 — 팀 전체 역할 분담 동시 실험 · 전부 기준 미달

담당	시도 내용	Private	vs 기준	원인
재하	**+ row_skew만 선별 추가**	0.8610	**-0.012**	피처 추가는 답이 아님을 재확인
재하	**+ row_skew + 핵심 피처 5개 (X_36·X_40·X_41·X_42·X_46)**	0.8638	**-0.010**	조합 정교화해도 기준 미달
나경	**+ 핵심 피처 5개 추가**	0.8414	**-0.032**	피처 단독 추가의 한계
성진	**+ row_skew + 핵심 피처 5개 + LGB + Auto-weight**	0.8353	**-0.038**	모델+피처 동시 추가 → 큰 폭 하락
다수	LGB + Optuna / Focal Loss 등 다양한 조합	기준 미달	❌	피처·모델·튜닝 어떤 방향도 통하지 않음

14

1차 기반 위 추가 시도

QDA + KMeans Soft Cluster — 더 넣으면 더 좋을 것이라는 마지막 가설

결론: 두 피처 블록 모두 LDA가 이미 잡은 신호와 겹쳐 입력만 비대해지고 점수 하락 · SNN(0.8744) → 0.8536 (-0.208)

시도 1 — QDA probability 피처 (21차원 추가)

가설 LDA(선형)가 못 잡는 비선형 분리를 QDA(이차)가 보강할 것이다

실패 QDA proba ≈ Mahalanobis의 정규화 버전 → LDA와 상관된 중복 신호
train fold fit 시 val/test 신뢰도 저하 (light leakage)

원인 같은 카테고리(centroid 기반 거리·확률)의 정보를 다른 형태로 반복 추가
→ 의도한 보강이 아닌 상관된 노이즈 추가로 귀결

시도 2 — KMeans Soft Cluster 피처 (38차원 추가)

가설 Unsupervised → 라벨 누수 없음. k=5·10·20 다중 해상도로 자연 군집 캡처

실패 이 데이터의 자연군집 = 클래스 군집과 거의 동치
→ KMeans 군집 = LDA의 열화 버전, 새 정보 없음

원인 k=5·10·20 계층적 상관 → 38차원이지만 실효 정보는 훨씬 적음
→ 차원만 1.8배(72→131) 늘고 진짜 신호는 추가되지 않음

입력 차원: SNN(0.8744) 72차원 → +QDA+Cluster 131차원 (+82%) → Private 0.8636 (-0.108)

핵심 교훈

01 **LDA가 이미 잡은 정보의 다른 표현 추가 = 거의 항상 손해**
supervised(LDA) · distance(Maha/QDA) · unsupervised(KMeans) — 셋 다 같은 카테고리

02 **차원 비대화는 성능 저하로 이어진다**
새 정보 없이 입력만 늘어나면 모델이 가짜 신호에 가중치를 분산

03 **추가 피처는 단일 모델 OOF ablation 후에만 적용**
가설상 좋아보여도 실제로는 아닌 경우가 많았음

CONCLUSION

한계점 및 결론

한계점

OOF / Private 갭 ~0.01

OOF 0.8780 → Private 0.8744. Covariate Shift 가능성.

AutoGluon LDA 누수 가능성

AG 0.2 고정 블렌딩 부분 · 전체 train에서 LDA fit.

Class 0/9/15 혼동 미해결

ClassWeight 보정에도 근본 분리 한계 존재.

+0.0134

Private 점수 개선

0.8598 → 0.8744

50+

수행한 실험 수

4명 협업 진행

Q & A